Atividade 2: Adaline

Disciplina: Redes Neurais Artificiais

Programa de Pós-Graduação em Ciência da Computação (PPGCC-UNESP)

21 de março de 2026

1 Introdução e Implementação

Este documento apresenta os resultados da implementação e avaliação do modelo ADALINE (Adaptive Linear Neuron). A implementação foi baseada no algoritmo do Perceptron, adaptando a regra de atualização dos pesos para utilizar o erro contínuo e minimizar o Erro Quadrático Médio (E_{qm}).

O algoritmo foi implementado suportando duas abordagens de treinamento, por amostra e por batch.

O bias foi fixado em 1 e inserido tanto nos vetores de entrada quanto inicializado de forma aleatória no vetor de pesos.

2 Experimentos: Dataset 1

O primeiro experimento foi conduzido em uma base de 2 atributos, com 140 amostras de treino e 60 amostras de teste. Os parâmetros utilizados foram: limite de 100 épocas, taxa de aprendizado $\eta = 0.01$ e critério de parada $\epsilon = 0.001$. Foram testadas as abordagens por Amostra e Batch.

2.1 Resultados Numéricos

Abordagem	**Épocas**	**EQM Final**	**Acc Treino**	**Acc Teste**
Amostra	5	0.2649	96.43%	95.00%
Batch	100	0.5385	82.86%	88.33%

Tabela 1: Resultados obtidos para o Dataset 1

2.2 Evolução dos Erros

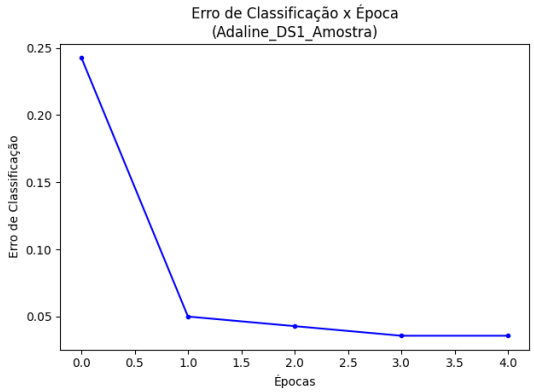

Figura 1: Erro de Classif. (Amostra - DS1)

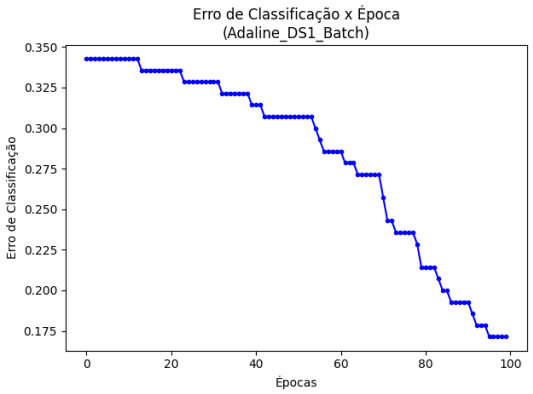

Figura 2: Erro de Classif. (Batch - DS1)

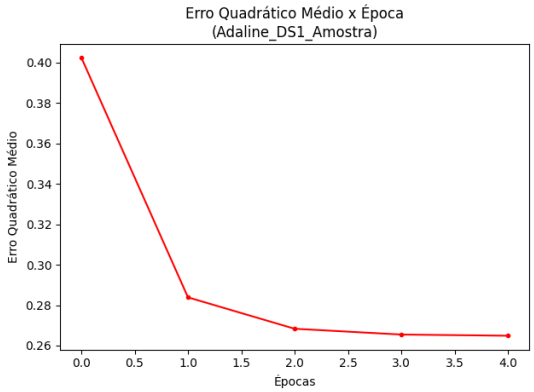

Figura 3: Erro Quadrático (Amostra - DS1)

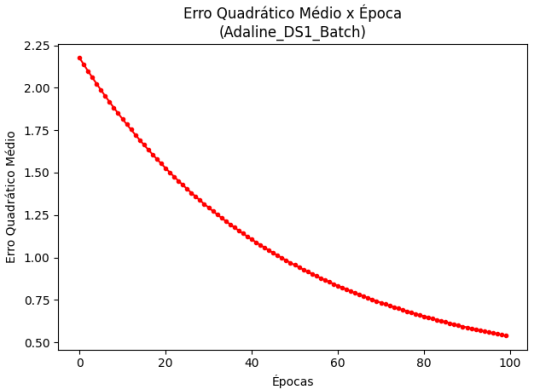

Figura 4: Erro Quadrático (Batch - DS1)

2.3 Fronteiras de Decisão (Treino e Teste)

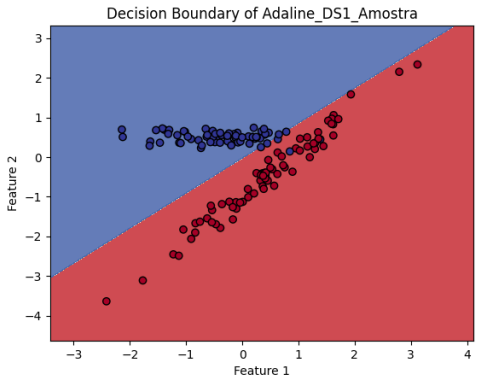

Figura 5: Fronteira Treino (Amostra - DS1)

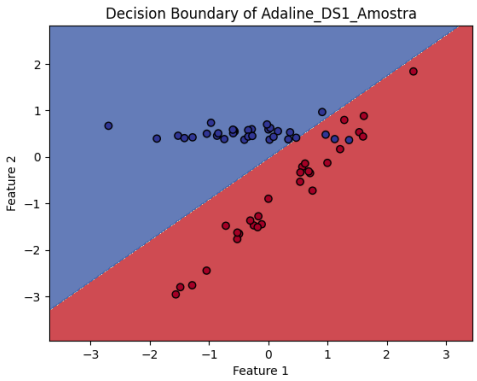

Figura 6: Fronteira Teste (Amostra - DS1)

Discussão (Dataset 1): Os resultados indicam que o Dataset 1 é amplamente separável linearmente. A abordagem por amostra convergiu muito rapidamente, em apenas 5 épocas, atingindo uma alta acurácia de 96.43% no treino e 95% no teste. Por outro lado, o modelo em lote (Batch) precisou de 100 épocas (parada pelo limite máximo) e obteve um desempenho inferior (88.33% no teste), sugerindo que a taxa de aprendizado de 0.01 pode não ter sido o ajuste ideal para o gradiente médio nesta distribuição específica.

3 Experimentos: Dataset 2

O segundo experimento utilizou uma base de 2 atributos com 175 amostras de treino e 75 amostras de teste, mantendo os mesmos hiperparâmetros ($\eta = 0.01$, $\epsilon = 0.001$, máx 100 épocas).

3.1 Resultados Numéricos

Abordagem	Épocas	EQM Final	Acc Treino	Acc Teste
Amostra	7	0.9981	45.71%	28.00%
Batch	100	1.2502	67.43%	70.67%

Tabela 2: Resultados obtidos para o Dataset 2

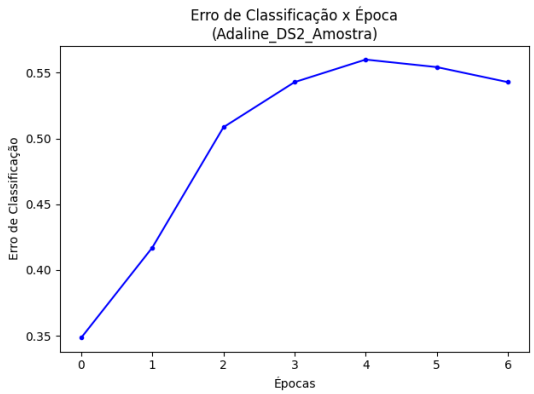

Figura 7: Erro de Classif. (Amostra - DS2)

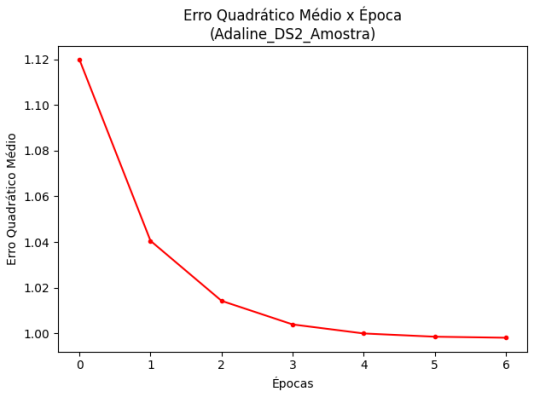

Figura 8: Erro Quadrático (Amostra - DS2)

Discussão (Dataset 2): Houve uma nítida dificuldade do modelo em classificar os dados do Dataset 2. A versão por amostra sofreu de convergência prematura em apenas 7 épocas, resultando em métricas extremamente baixas (28% no teste). A versão em Batch obteve um desempenho ligeiramente melhor e mais coerente (cerca de 70% de acurácia), esgotando as 100 épocas. A principal conclusão é que, diferentemente do Dataset 1, estes dados possivelmente não são linearmente separáveis ou requerem um ajuste fino de parâmetros e mais épocas para a versão Batch assentar adequadamente a fronteira.

4 Experimentos: Dataset 3

O Dataset 3 apresenta maior complexidade, contando com 10 atributos (147 amostras de treino e 63 de teste). Foram avaliadas múltiplas combinações de taxa de aprendizado ($\eta \in \{0.01, 0.001, 0.0001\}$) e critério de parada ($\epsilon \in \{0.1, 0.0001\}$), rodando por até 100 épocas. A fronteira de decisão (gráficos) foi omitida devido à alta dimensionalidade dos dados (>3D).

4.1 Comparativo de Hiperparâmetros

η	ϵ	**Épocas (Am)**	**Ac. Treino (Am)**	**Ac. Teste (Am)**	**Épocas (Ba)**	**Ac. Treino (Ba)**	**Ac. Teste (Ba)**
0.01	0.1	3	93.88%	87.30%	12	60.54%	60.32%
0.01	0.0001	6	93.88%	85.71%	100	78.91%	76.19%
0.001	0.1	9	82.31%	76.19%	2	57.14%	57.14%
0.001	0.0001	37	93.88%	88.89%	100	60.54%	60.32%
0.0001	0.1	18	65.31%	63.49%	2	57.14%	57.14%
0.0001	0.0001	100	84.35%	80.95%	100	57.14%	57.14%

Tabela 3: Amostra (Am) vs Batch (Ba) no Dataset 3

4.2 Análise Gráfica do EQM (Exemplos)

Abaixo apresentamos gráficos ilustrativos do E_{qm} para diferentes combinações e abordagens:

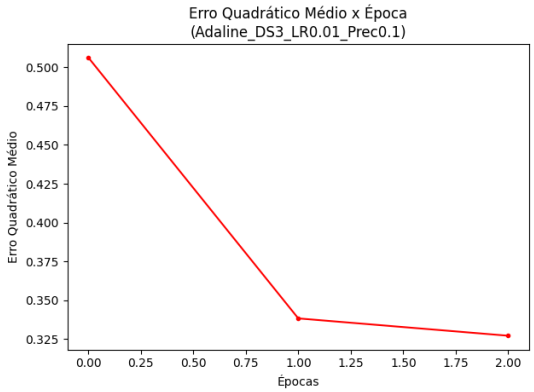

Figura 9: EQM: $\eta = 0.01, \epsilon = 0.1$ (Amostra)

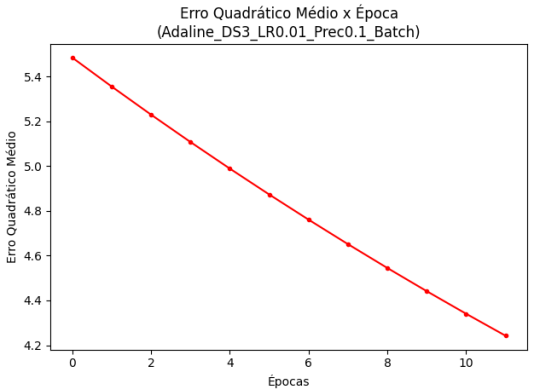

Figura 10: EQM: $\eta = 0.01, \epsilon = 0.1$ (Batch)

Discussão (Dataset 3): A dimensionalidade mais elevada expôs de forma muito clara as diferenças entre os métodos de aprendizado. O método de Amostra obteve resultados de excelência em quase todas as configurações, em especial com $\eta = 0.01$ e $\eta = 0.001$, beirando 94% de acurácia em épocas baixas. Por outro lado, o modelo Batch enfrentou severas dificuldades; quando $\epsilon = 0.1$, a diferença entre as épocas ficou abaixo da tolerância rapidamente e o treino parou prematuramente (com apenas 2 épocas nos η mais baixos). Mesmo quando forçado a rodar 100 épocas (com precisão mais rigorosa), o modelo Batch ficou preso em taxas de acurácia marginais (cerca de 57% a 60%). Isso mostra como, em certos cenários multidimensionais com ruído, as atualizações ruidosas amostra por amostra podem ajudar a escapar de mínimos subótimos rasos e encontrar uma solução muito melhor do que o gradiente suave do Batch.