

Atividade 4: Redes Convolucionais (CNN)

Disciplina: Redes Neurais Artificiais

Programa de Pós-Graduação em Ciência da Computação (PPGCC-UNESP)

5 de maio de 2026

1 Introdução e Implementação

Este documento apresenta os resultados da implementação e avaliação de redes neurais convolucionais (CNNs) para classificação de imagens no conjunto de dados CIFAR-10. O dataset contém imagens RGB de 32×32 pixels distribuídas em 10 classes: avião, carro, pássaro, gato, cervo, cachorro, sapo, cavalo, navio e caminhão.

A CNN foi construída do zero utilizando o módulo `nn.Module` do PyTorch, sem o uso de modelos prontos. A arquitetura é parametrizável, permitindo instanciar diferentes topologias variando o número de camadas convolucionais, número de filtros e taxa de dropout. Cada bloco convolucional é composto por uma camada `Conv2d`, ativação `ReLU` e `MaxPool2d` (kernel 2×2 , stride 2). Após o extrator de características, a cabeça classificadora consiste em três camadas totalmente conectadas (`FC1` e `FC2` com 200 neurônios cada, `FC3` com 10 saídas), com `Dropout` entre elas. A função de perda utilizada é a `CrossEntropyLoss` e os otimizadores avaliados são SGD e Adam.

O conjunto de treino (50.000 imagens) foi dividido em 90% para treino efetivo e 10% para validação, com *early stopping* de paciência 5 épocas. O conjunto de teste (10.000 imagens) foi utilizado exclusivamente para avaliação final. As imagens foram normalizadas para média 0,5 e desvio padrão 0,5 por canal.

2 Arquiteturas e Experimentos

Foram testadas 36 arquiteturas combinando os seguintes hiperparâmetros:

- **Otimizadores:** SGD, Adam
- **Camadas convolucionais:** 2, 3, 4
- **Filtros:** 32, 64, 128
- **Dropout nas camadas FC:** $p = 0,1$ e $p = 0,3$

Todos os modelos foram treinados por até 30 épocas com *early stopping*. A seguir, apresentam-se os resultados completos no conjunto de teste.

Tabela 1: Resultados completos no conjunto de teste – CIFAR-10

Otim.	Conv	Filtros	Dropout	Test Loss	Test Acc	Épocas
SGD	2	32	0.1	1.5717	0.4305	30
SGD	2	32	0.3	1.6879	0.3900	30
SGD	2	64	0.1	1.4878	0.4575	30
SGD	2	64	0.3	1.5302	0.4490	30
SGD	2	128	0.1	1.3779	0.5005	30
SGD	2	128	0.3	1.4445	0.4789	30
SGD	3	32	0.1	1.9177	0.3056	30
SGD	3	32	0.3	2.2710	0.2494	30
SGD	3	64	0.1	1.8110	0.3452	30
SGD	3	64	0.3	1.8894	0.3090	30
SGD	3	128	0.1	1.6567	0.4000	30
SGD	3	128	0.3	1.7831	0.3477	30
SGD	4	32	0.1	2.3016	0.1023	30
SGD	4	32	0.3	2.2866	0.1347	30
SGD	4	64	0.1	2.2829	0.1352	30
SGD	4	64	0.3	2.2942	0.1996	30
SGD	4	128	0.1	2.2753	0.1693	30
SGD	4	128	0.3	2.2720	0.2148	30
Adam	2	32	0.1	1.0548	0.7083	10
Adam	2	32	0.3	0.9303	0.7050	13
Adam	2	64	0.1	1.0858	0.7199	10
Adam	2	64	0.3	0.9838	0.7204	13
Adam	2	128	0.1	1.1261	0.7331	10
Adam	2	128	0.3	0.9431	0.7269	10
Adam	3	32	0.1	0.8228	0.7337	12
Adam	3	32	0.3	0.8069	0.7304	14
Adam	3	64	0.1	1.0178	0.7324	15
Adam	3	64	0.3	0.8406	0.7511	16
Adam	3	128	0.1	0.8726	0.7629	10
Adam	3	128	0.3	0.7672	0.7595	11
Adam	4	32	0.1	0.8440	0.7186	13
Adam	4	32	0.3	0.8374	0.7265	17
Adam	4	64	0.1	0.9404	0.7354	14
Adam	4	64	0.3	0.8777	0.7394	15
Adam	4	128	0.1	0.8780	0.7646	12
Adam	4	128	0.3	0.8770	0.7504	11


Valores em **negrito** indicam o melhor resultado em cada métrica.

3 Análises e Discussão


3.1 Impacto do Otimizador

A diferença mais marcante observada nos experimentos é a superioridade absoluta do Adam sobre o SGD no contexto de CNNs treinadas no CIFAR-10. Enquanto o Adam produziu acurácias entre 70% e 76%, todas as configurações com SGD ficaram abaixo de 51%, e as arquiteturas com 4 camadas convolucionais e SGD chegaram a colapsar próximas à acurácia aleatória ($\approx 10\%$), indicando falha de convergência. Esse comportamento contrasta com a atividade anterior (MLP), onde SGD e Adam apresentaram resultados mais equilibrados no dataset multiclasse. A taxa de aprendizado adaptativa do Adam mostra-se essencial para navegar a superfície de perda mais complexa de uma CNN.


Outro dado relevante é que os modelos Adam atingiram *early stopping* bem antes das 30 épocas (entre 10 e 17 épocas), enquanto todos os modelos SGD executaram as 30 épocas completas sem convergir adequadamente. Abaixo, curvas de treino e validação de acurácia e erro para SGD e Adam com a mesma configuração base (Conv2, 128 filtros, $p = 0,1$):




SGD – Acurácia de treino




Adam – Acurácia de treino




SGD – Acurácia de validação




Adam – Acurácia de validação




SGD – Erro de treino



Adam – Erro de treino



SGD – Erro de validação




Adam – Erro de validação


3.2 Impacto do Número de Camadas Convolucionais

Para o SGD, o desempenho piora monotonicamente com o aumento do número de camadas: 2 camadas resultam em acurácia média de $\approx 45\%$, 3 camadas de $\approx 33\%$ e 4 camadas de $\approx 16\%$. Isso indica que, sem uma taxa de aprendizado adaptativa, adicionar profundidade dificulta a otimização – possivelmente por problemas de gradiente vanescente agravados pelo MaxPooling repetido que reduz o mapa espacial a 2×2 com 4 camadas.


Para o Adam, o padrão é diferente: 3 e 4 camadas convolucionais superam as arquiteturas com 2 camadas. A melhor acurácia geral (**76,46%**) foi obtida com 4 camadas convolucionais, 128 filtros e $p = 0,1$. Isso sugere que, com o otimizador adequado, maior profundidade extrai representações mais ricas e hierárquicas das imagens CIFAR-10.




SGD – Conv2 (validação)




SGD – Conv3 (validação)




SGD – Conv4 (validação)



Adam – Conv2 (validação)




Adam – Conv3 (validação)




Adam – Conv4 (validação)

3.3 Impacto do Número de Filtros


Em todas as configurações, aumentar o número de filtros melhora o desempenho. Para o Adam com 3 camadas convolucionais, a acurácia média sobe de $\approx 73\%$ com 32 filtros para $\approx 76\%$ com 128 filtros. Filtros adicionais permitem ao extrator de características capturar mais padrões visuais distintos por camada, o que é especialmente relevante para um dataset com 10 classes visualmente variadas.




SGD – 32 filtros




SGD – 64 filtros




SGD – 128 filtros



Adam – 32 filtros



Adam – 64 filtros



Adam – 128 filtros


3.4 Impacto do Dropout

O impacto do dropout nas camadas FC foi sutil, porém observável. A tabela 2 resume as médias por taxa de dropout separadas por otimizador.


Tabela 2: Impacto do Dropout – média de acurácia e loss no teste

Otimizador	Dropout	Acc (μ)	Loss (μ)
SGD	0.1	0.3284	1.8639
SGD	0.3	0.2974	1.9399
Adam	0.1	0.7309	0.9290
Adam	0.3	0.7316	0.8743


Para o SGD, o dropout $p = 0,3$ prejudica levemente os resultados, possivelmente porque a rede já converge mal e o dropout adiciona mais variância ao gradiente. Para o Adam, os resultados são praticamente equivalentes entre $p = 0,1$ e $p = 0,3$, com uma leve vantagem de loss para $p = 0,3$ (indicando menor sobreajuste) mas acurácia muito próxima. Isso sugere que, para esta arquitetura, o dropout nas camadas FC tem efeito marginal como regularizador, e que o principal fator diferenciador entre os modelos é o otimizador e a profundidade da rede.




SGD – Dropout $p = 0,1$ (validação)



SGD – Dropout $p = 0,3$ (validação)



Adam – Dropout $p = 0,1$ (validação)



Adam – Dropout $p = 0,3$ (validação)

3.5 Melhor Configuração

Tabela 3: Melhor configuração por otimizador (maior acurácia no teste)

Otim.	Conv	Filtros	Dropout	Loss	Acc
SGD	2	128	0.1	1.3779	0.5005
Adam	4	128	0.1	0.8780	0.7646

O melhor modelo geral foi Adam_Conv4_Filt128_Drop0.1, com acurácia de **76,46%** no teste, atingindo *early stopping* na época 12. Para o SGD, o melhor resultado foi SGD_Conv2_Filt128_Drop0.1 com 50,05% – menos de 27 pontos percentuais abaixo do melhor Adam, o que é uma diferença expressiva.

4 Conclusão

Os experimentos com CNNs no CIFAR-10 revelam padrões distintos dos observados na MLP da atividade anterior. O otimizador Adam mostrou-se indispensável para a convergência das redes convolucionais neste contexto, enquanto o SGD falhou sistematicamente, especialmente em arquiteturas mais profundas.

O aumento de filtros e de camadas convolucionais beneficia o Adam de forma consistente, corroborando a intuição de que redes mais profundas extraem representações hierárquicas mais ricas. O dropout nas camadas FC, por sua vez, apresentou impacto marginal sobre a acurácia final, sendo o otimizador e a profundidade os fatores determinantes.

Respondendo às questões da atividade:

Impacto do número de camadas e filtros: Mais camadas e mais filtros melhoram a acurácia quando combinados com Adam. Com SGD, camadas adicionais prejudicam a convergência.

Dropout e overfitting: O dropout teve efeito limitado nesta configuração. A maior ameaça ao overfitting observada foram os modelos Adam com poucas épocas de treino, que ainda assim generalizaram razoavelmente bem.

Generalização no conjunto de teste: O melhor modelo (Adam, 4 convoluções, 128 filtros) atingiu 76,46% de acurácia no teste, valor competitivo para uma CNN simples sem *data augmentation* no CIFAR-10.