Atividade 3: MLP

Disciplina: Redes Neurais Artificiais

Programa de Pós-Graduação em Ciência da Computação (PPGCC-UNESP)

14 de abril de 2026

1 Introdução e Implementação

Este documento apresenta os resultados da implementação e avaliação do modelo MLP (Multilayer Perceptron). A MLP foi construída com o módulo de python conhecido como PyTorch, que provê implementações pré construídas importantes e otimizadas para GPU. Escolheu-se utilizar o DataLoader do Torch e uma arquitetura genérica para qualquer entrada, onde a rede deve identificar o tipo de problema de classificação (binário ou multiclasse), a partir dai definindo as funções de ativação ReLU ou Tahn, assim como o tamanho da camada final.

Como o CrossEntropy já aplica o softmax, o problema multiclasse é naturalmente resolvido, precisa-se apenas selecionar o argmax. No binário, é necessário ativar o vetor de 2 posições de saída, logo, pode-se usar a função sigmoid para ativar a saida do modelo e daí enviar para função BCELoss. Se usarmos a BCEWithLogitsLoss, esse sigmoid é automaticamente aplicado.

Utilizou-se o scikit_learn para calcular-se as métricas, como f1_score, AUC-ROC e acurácia. A sequência de testes foi estabelecida usando uma combinação entre conjuntos de arquiteturas, funções de ativação, datasets, otimizadores e tipos de regularização. Seguem exemplos dos treinos nessa estrutura.

2 Experimentos no Dataset 1 e 2

Os datasets 1 e 2 tinham uma natureza de classificação binária, o que se torna um problema trivial para uma MLP com até 3 camadas, o que, naturalmente, também gera um overfitting muito alto. Neste caso, não há nenhum problema nisso, pois os dados estão bem distribuidos e mesmo ao amostrar o dataset, os padrões permanecem. No entanto, num caso onde houvesse possível ruído, a mlp seria sobre treinada e retornaria resultados ruins para este problema bidimensional.

Abaixo, alguns exemplos de resultados:

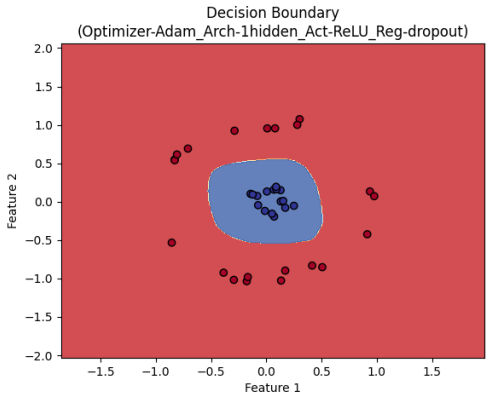

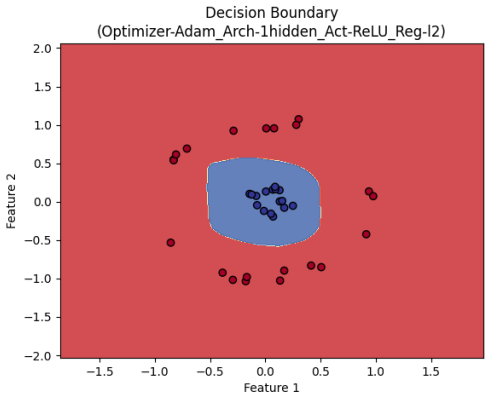

Podemos ver os efeitos, no entanto, do overfitting supracitado nos dados de teste:

Tabela 1: Resultados completos no conjunto de teste – Dataset 1

Otim.	**Arq.**	**Ativ.**	**Reg.**	**Loss**	**Acc**	**F1**	**AUC**	**Tr.Acc**	**Val.Acc**
SGD	[2, 64, 1]	ReLU	none	0.1659	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
SGD	[2, 64, 1]	ReLU	dropout	0.1858	**0.9667**	**0.9666**	0.9955	0.9786	0.9333
SGD	[2, 64, 1]	ReLU	l2	0.1532	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
SGD	[2, 64, 1]	Tanh	none	0.1430	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
SGD	[2, 64, 1]	Tanh	dropout	0.1576	**0.9667**	**0.9666**	0.9955	0.9786	0.9333
SGD	[2, 64, 1]	Tanh	l2	0.1437	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
SGD	[2, 128, 64, 1]	ReLU	none	0.1213	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
SGD	[2, 128, 64, 1]	ReLU	dropout	0.1244	**0.9667**	**0.9666**	**1.0000**	0.9786	0.9333
SGD	[2, 128, 64, 1]	ReLU	l2	0.1256	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
SGD	[2, 128, 64, 1]	Tanh	none	0.1110	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
SGD	[2, 128, 64, 1]	Tanh	dropout	0.1095	**0.9667**	**0.9666**	0.9955	0.9786	0.9333
SGD	[2, 128, 64, 1]	Tanh	l2	0.1129	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
SGD	[2, 256, 128, 64, 1]	ReLU	none	0.1070	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
SGD	[2, 256, 128, 64, 1]	ReLU	dropout	0.1070	**0.9667**	**0.9666**	**1.0000**	0.9786	0.9333
SGD	[2, 256, 128, 64, 1]	ReLU	l2	0.1180	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
SGD	[2, 256, 128, 64, 1]	Tanh	none	0.1054	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
SGD	[2, 256, 128, 64, 1]	Tanh	dropout	0.1086	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
SGD	[2, 256, 128, 64, 1]	Tanh	l2	0.1007	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
Adam	[2, 64, 1]	ReLU	none	0.1051	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 64, 1]	ReLU	dropout	0.1019	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 64, 1]	ReLU	l2	0.1009	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 64, 1]	Tanh	none	0.1029	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
Adam	[2, 64, 1]	Tanh	dropout	0.1044	**0.9667**	**0.9666**	0.9955	0.9786	0.9333
Adam	[2, 64, 1]	Tanh	l2	0.1037	**0.9667**	**0.9666**	0.9955	**0.9857**	0.9333
Adam	[2, 128, 64, 1]	ReLU	none	0.0698	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 128, 64, 1]	ReLU	dropout	0.0684	**0.9667**	**0.9666**	**1.0000**	0.9786	0.9333
Adam	[2, 128, 64, 1]	ReLU	l2	0.0789	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 128, 64, 1]	Tanh	none	0.1032	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 128, 64, 1]	Tanh	dropout	0.1063	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 128, 64, 1]	Tanh	l2	0.0869	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 256, 128, 64, 1]	ReLU	none	0.0581	**0.9667**	**0.9666**	**1.0000**	**0.9857**	**0.9667**
Adam	[2, 256, 128, 64, 1]	ReLU	dropout	**0.0533**	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 256, 128, 64, 1]	ReLU	l2	0.0665	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 256, 128, 64, 1]	Tanh	none	0.0724	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 256, 128, 64, 1]	Tanh	dropout	0.0885	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333
Adam	[2, 256, 128, 64, 1]	Tanh	l2	0.0956	**0.9667**	**0.9666**	**1.0000**	**0.9857**	0.9333

Valores em **negrito** indicam o melhor resultado em cada métrica.

O mesmo se aplica para o dataset 2:

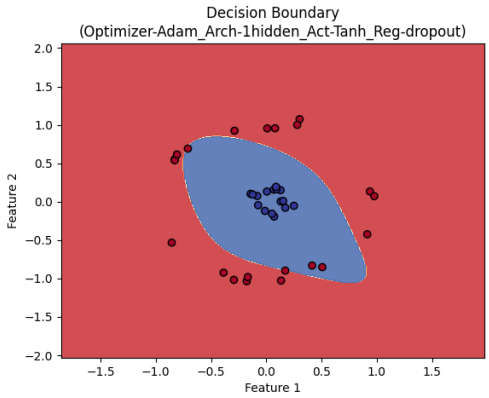

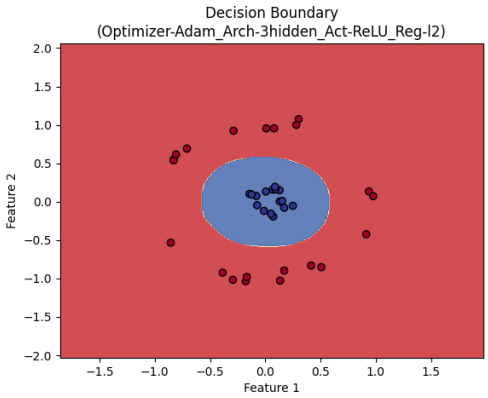

Tabela 2: Resultados completos no conjunto de teste – Dataset 2

Otim.	**Arq.**	**Ativ.**	**Reg.**	**Loss**	**Acc**	**F1**	**AUC**	**Tr.Acc**	**Val.Acc**
SGD	[2, 64, 1]	ReLU	none	0.4931	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
SGD	[2, 64, 1]	ReLU	dropout	0.5876	**1.0000**	**1.0000**	**1.0000**	0.9371	**1.0000**
SGD	[2, 64, 1]	ReLU	l2	0.5152	0.9730	0.9731	**1.0000**	0.9943	0.9737
SGD	[2, 64, 1]	Tanh	none	0.6738	0.6216	0.5846	0.6756	0.6857	0.6053
SGD	[2, 64, 1]	Tanh	dropout	0.6705	0.6757	0.6550	0.5952	0.6571	0.6842
SGD	[2, 64, 1]	Tanh	l2	0.6718	0.6486	0.6206	0.7054	0.7257	0.6842
SGD	[2, 128, 64, 1]	ReLU	none	0.5308	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
SGD	[2, 128, 64, 1]	ReLU	dropout	0.4344	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
SGD	[2, 128, 64, 1]	ReLU	l2	0.4101	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
SGD	[2, 128, 64, 1]	Tanh	none	0.6492	0.6216	0.5846	0.8839	0.7086	0.6316
SGD	[2, 128, 64, 1]	Tanh	dropout	0.6615	0.5676	0.5066	0.9107	0.6514	0.5789
SGD	[2, 128, 64, 1]	Tanh	l2	0.6724	0.6216	0.5846	0.5863	0.7200	0.6842
SGD	[2, 256, 128, 64, 1]	ReLU	none	0.4637	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
SGD	[2, 256, 128, 64, 1]	ReLU	dropout	0.4781	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
SGD	[2, 256, 128, 64, 1]	ReLU	l2	0.4851	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
SGD	[2, 256, 128, 64, 1]	Tanh	none	0.6749	0.6216	0.5846	0.6042	0.7200	0.6842
SGD	[2, 256, 128, 64, 1]	Tanh	dropout	0.6689	0.6216	0.5846	0.6071	0.7086	0.6842
SGD	[2, 256, 128, 64, 1]	Tanh	l2	0.6592	0.6216	0.5846	0.6845	0.7143	0.6842
Adam	[2, 64, 1]	ReLU	none	0.0832	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 64, 1]	ReLU	dropout	0.0975	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 64, 1]	ReLU	l2	0.1333	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 64, 1]	Tanh	none	0.4761	**1.0000**	**1.0000**	**1.0000**	0.9943	**1.0000**
Adam	[2, 64, 1]	Tanh	dropout	0.4891	0.9189	0.9193	**1.0000**	0.9314	0.8947
Adam	[2, 64, 1]	Tanh	l2	0.5393	0.8919	0.8922	**1.0000**	0.9657	**1.0000**
Adam	[2, 128, 64, 1]	ReLU	none	0.0007	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 128, 64, 1]	ReLU	dropout	0.0005	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 128, 64, 1]	ReLU	l2	0.0041	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 128, 64, 1]	Tanh	none	0.0076	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 128, 64, 1]	Tanh	dropout	0.0142	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 128, 64, 1]	Tanh	l2	0.0158	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 256, 128, 64, 1]	ReLU	none	**0.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 256, 128, 64, 1]	ReLU	dropout	**0.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 256, 128, 64, 1]	ReLU	l2	0.0016	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 256, 128, 64, 1]	Tanh	none	0.0007	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 256, 128, 64, 1]	Tanh	dropout	0.0005	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**
Adam	[2, 256, 128, 64, 1]	Tanh	l2	0.0046	**1.0000**	**1.0000**	**1.0000**	**1.0000**	**1.0000**

Valores em **negrito** indicam o melhor resultado em cada métrica.

Vemos que os resultados do datasets 2 estão no geral próximo a 1 com qualquer arquitetura com no mínimo 2 camadas escondidas e que o Adam se comportou muito bem para este dataset em especial, padrão que não será constatado no problema a seguir.

3 Experimentos no Dataset 4

O Dataset 4 é consideravelmente mais complexo, como pode ser visto nos resultdos a seguir, devido, mas não só à sua natureza multiclasse. Foram treinadas 100 épocas por arquitetura (com early stopping ativado), seguem os resultados:

Tabela 3: Resultados completos no conjunto de teste – Dataset 4

Otim.	**Arq.**	**Ativ.**	**Reg.**	**Loss**	**Acc**	**F1**	**AUC**	**Tr.Acc**	**Val.Acc**
SGD	[50, 64, 4]	ReLU	none	0.5859	0.7917	0.7904	**0.9483**	0.9102	0.7812
SGD	[50, 64, 4]	ReLU	dropout	**0.5822**	0.7958	0.7959	0.9476	0.8893	0.8073
SGD	[50, 64, 4]	ReLU	l2	0.5826	0.7958	0.7958	0.9453	0.8958	0.8021
SGD	[50, 64, 4]	Tanh	none	0.6021	0.8083	0.8092	0.9422	0.8529	0.7917
SGD	[50, 64, 4]	Tanh	dropout	0.5916	0.8083	0.8090	0.9439	0.8542	0.8073
SGD	[50, 64, 4]	Tanh	l2	0.5912	0.8042	0.8040	0.9431	0.8568	0.7917
SGD	[50, 128, 64, 4]	ReLU	none	0.6052	0.7792	0.7796	0.9463	0.9245	0.7865
SGD	[50, 128, 64, 4]	ReLU	dropout	0.5903	0.7917	0.7919	0.9481	0.9102	0.7865
SGD	[50, 128, 64, 4]	ReLU	l2	0.6045	0.7958	0.7953	0.9442	0.9102	0.7917
SGD	[50, 128, 64, 4]	Tanh	none	0.5950	0.7917	0.7918	0.9436	0.8594	0.8073
SGD	[50, 128, 64, 4]	Tanh	dropout	0.5984	0.7958	0.7954	0.9430	0.8490	0.7969
SGD	[50, 128, 64, 4]	Tanh	l2	0.5837	0.8042	0.8046	0.9447	0.8542	0.8073
SGD	[50, 256, 128, 64, 4]	ReLU	none	0.6297	**0.8167**	**0.8167**	0.9463	0.9414	0.8073
SGD	[50, 256, 128, 64, 4]	ReLU	dropout	0.6177	0.8000	0.7993	0.9458	0.8958	0.7969
SGD	[50, 256, 128, 64, 4]	ReLU	l2	0.6207	0.8125	0.8119	0.9453	0.9375	0.7708
SGD	[50, 256, 128, 64, 4]	Tanh	none	0.5946	0.8042	0.8042	0.9439	0.8594	0.8073
SGD	[50, 256, 128, 64, 4]	Tanh	dropout	0.5961	0.8042	0.8033	0.9433	0.8516	0.8125
SGD	[50, 256, 128, 64, 4]	Tanh	l2	0.5907	0.8125	0.8130	0.9434	0.8542	0.7969
Adam	[50, 64, 4]	ReLU	none	0.7077	0.7625	0.7621	0.9402	0.9909	0.7552
Adam	[50, 64, 4]	ReLU	dropout	0.6557	0.7833	0.7826	0.9416	0.9688	0.7656
Adam	[50, 64, 4]	ReLU	l2	0.6408	0.7875	0.7870	0.9450	0.9948	0.7604
Adam	[50, 64, 4]	Tanh	none	0.6668	0.7792	0.7785	0.9374	0.8958	0.7865
Adam	[50, 64, 4]	Tanh	dropout	0.6522	0.7792	0.7772	0.9414	0.8815	0.7969
Adam	[50, 64, 4]	Tanh	l2	0.6564	0.7625	0.7615	0.9390	0.8945	0.7812
Adam	[50, 128, 64, 4]	ReLU	none	0.9396	0.7708	0.7698	0.9433	1.0000	0.7448
Adam	[50, 128, 64, 4]	ReLU	dropout	0.9494	0.7958	0.7948	0.9397	0.9948	0.7656
Adam	[50, 128, 64, 4]	ReLU	l2	0.9169	0.7958	0.7943	0.9410	1.0000	0.7552
Adam	[50, 128, 64, 4]	Tanh	none	0.6737	0.7792	0.7779	0.9425	0.9492	0.7812
Adam	[50, 128, 64, 4]	Tanh	dropout	0.6681	0.7875	0.7883	0.9408	0.9062	0.8073
Adam	[50, 128, 64, 4]	Tanh	l2	0.6750	0.7875	0.7870	0.9400	0.9297	0.7865
Adam	[50, 256, 128, 64, 4]	ReLU	none	1.3326	0.7750	0.7752	0.9354	1.0000	0.7917
Adam	[50, 256, 128, 64, 4]	ReLU	dropout	1.3325	0.7667	0.7644	0.9415	1.0000	0.7500
Adam	[50, 256, 128, 64, 4]	ReLU	l2	1.1137	0.7708	0.7710	0.9407	1.0000	0.7500
Adam	[50, 256, 128, 64, 4]	Tanh	none	0.8093	0.8000	0.7994	0.9310	0.9870	0.7865
Adam	[50, 256, 128, 64, 4]	Tanh	dropout	0.8458	0.7833	0.7831	0.9280	0.9622	0.7760
Adam	[50, 256, 128, 64, 4]	Tanh	l2	0.7506	0.7875	0.7859	0.9368	0.9805	0.7917

Valores em **negrito** indicam o melhor resultado em cada métrica.

3.1 Discussão

Os 2 melhores resultados obtidos no dataset 4 não possuem nenhuma técnica de regularização, o que não necessariamente reflete um padrão. Haja vista que os melhores resultados de cada otimizador não estão exatamente na média dos resultados, o que demonstra que a regularização não obrigatoriamente melhora os resultados, mas, diminui consideravelmente o desvio padrão enquanto aumenta a média de resultados positivos. Observa-se que, diferentemente dos datasets binários anteriores, o uso do Adam em detrimento do SGD já não é mais lugar comum, agora, os resultados estão próximos e, na maioria dos testes, o SGD conseguiu resultados superiores ao Adam.

Tabela 4: Melhor configuração por otimizador (maior acurácia de teste)

Otim.	**Arq.**	**Ativ.**	**Reg.**	**Loss**	**Acc**	**F1**	**AUC**
SGD	[50, 256, 128, 64, 4]	ReLU	none	0.6297	0.8167	0.8167	0.9463
Adam	[50, 256, 128, 64, 4]	Tanh	none	0.8093	0.8000	0.7994	0.9310

Tabela 5: Impacto da regularização (média ± desvio sobre todas as combinações)

Regularização	**Acc** ($\mu \pm \sigma$)	**Loss** ($\mu \pm \sigma$)	**F1** (μ)	**AUC** (μ)
Dropout ($p = 0.1$)	0.7910 ± 0.0116	0.7233 ± 0.2232	0.7904	0.9421
L2 ($\lambda = 0.001$)	**0.7930 ± 0.0152**	0.6939 ± 0.1632	0.7926	0.9424
Nenhuma	0.7882 ± 0.0166	0.7285 ± 0.2175	0.7879	0.9417

Vê-se, como supracitado, que os valores médios tem uma significativa melhora com as regularizações propostas, mas que não necessariamente garantem o resltado ótimo.

Ao analisar o gap[1], é possível notar que o SGD possui, na média, um valor menor em comparação ao Adam. Ainda assim, é possível ver que com o gap consideravelmente alto pode indicar um possível overfitting. A tabela 6 apresenta os valores comparativos do gap.

Tabela 6: Análise de overfitting: gap entre acurácia de treino e validação

Otim.	**Arq.**	**Ativ.**	**Reg.**	**Tr.Acc**	**Val.Acc**	**Ts.Acc**	**Gap[1]**
Adam	[50, 128, 64, 4]	ReLU	none	1.0000	0.7448	0.7708	**0.2552**
Adam	[50, 256, 128, 64, 4]	ReLU	dropout	1.0000	0.7500	0.7667	**0.2500**
Adam	[50, 256, 128, 64, 4]	ReLU	l2	1.0000	0.7500	0.7708	**0.2500**
Adam	[50, 128, 64, 4]	ReLU	l2	1.0000	0.7552	0.7958	**0.2448**
Adam	[50, 64, 4]	ReLU	none	0.9909	0.7552	0.7625	**0.2357**
Adam	[50, 64, 4]	ReLU	l2	0.9948	0.7604	0.7875	**0.2344**
Adam	[50, 128, 64, 4]	ReLU	dropout	0.9948	0.7656	0.7958	**0.2292**
Adam	[50, 256, 128, 64, 4]	ReLU	none	1.0000	0.7917	0.7750	**0.2083**
Adam	[50, 64, 4]	ReLU	dropout	0.9688	0.7656	0.7833	**0.2032**
Adam	[50, 256, 128, 64, 4]	Tanh	none	0.9870	0.7865	0.8000	**0.2005**
Adam	[50, 256, 128, 64, 4]	Tanh	l2	0.9805	0.7917	0.7875	**0.1888**
Adam	[50, 256, 128, 64, 4]	Tanh	dropout	0.9622	0.7760	0.7833	**0.1862**
Adam	[50, 128, 64, 4]	Tanh	none	0.9492	0.7812	0.7792	**0.1680**
SGD	[50, 256, 128, 64, 4]	ReLU	l2	0.9375	0.7708	0.8125	**0.1667**
Adam	[50, 128, 64, 4]	Tanh	l2	0.9297	0.7865	0.7875	**0.1432**
SGD	[50, 128, 64, 4]	ReLU	none	0.9245	0.7865	0.7792	**0.1380**
SGD	[50, 256, 128, 64, 4]	ReLU	none	0.9414	0.8073	0.8167	**0.1341**
SGD	[50, 64, 4]	ReLU	none	0.9102	0.7812	0.7917	**0.1290**
SGD	[50, 128, 64, 4]	ReLU	dropout	0.9102	0.7865	0.7917	**0.1237**
SGD	[50, 128, 64, 4]	ReLU	l2	0.9102	0.7917	0.7958	**0.1185**
Adam	[50, 64, 4]	Tanh	l2	0.8945	0.7812	0.7625	**0.1133**
Adam	[50, 64, 4]	Tanh	none	0.8958	0.7865	0.7792	**0.1093**
Adam	[50, 128, 64, 4]	Tanh	dropout	0.9062	0.8073	0.7875	0.0989
SGD	[50, 256, 128, 64, 4]	ReLU	dropout	0.8958	0.7969	0.8000	0.0989
SGD	[50, 64, 4]	ReLU	l2	0.8958	0.8021	0.7958	0.0937
Adam	[50, 64, 4]	Tanh	dropout	0.8815	0.7969	0.7792	0.0846
SGD	[50, 64, 4]	ReLU	dropout	0.8893	0.8073	0.7958	0.0820
SGD	[50, 64, 4]	Tanh	l2	0.8568	0.7917	0.8042	0.0651
SGD	[50, 64, 4]	Tanh	none	0.8529	0.7917	0.8083	0.0612
SGD	[50, 256, 128, 64, 4]	Tanh	l2	0.8542	0.7969	0.8125	0.0573
SGD	[50, 128, 64, 4]	Tanh	dropout	0.8490	0.7969	0.7958	0.0521
SGD	[50, 128, 64, 4]	Tanh	none	0.8594	0.8073	0.7917	0.0521
SGD	[50, 256, 128, 64, 4]	Tanh	none	0.8594	0.8073	0.8042	0.0521
SGD	[50, 64, 4]	Tanh	dropout	0.8542	0.8073	0.8083	0.0469
SGD	[50, 128, 64, 4]	Tanh	l2	0.8542	0.8073	0.8042	0.0469
SGD	[50, 256, 128, 64, 4]	Tanh	dropout	0.8516	0.8125	0.8042	0.0391

Pode-se observar na tabela 7, em consonância, que as funções de ativação tem pouca diferença entre os resultados obtidos, sendo a acurácia da ReLU ou Tanh muita próximas no geral.

Tabela 7: Média das métricas por Função de Ativação – Dataset 4

Ativação	**Loss**	**Acc**	**F1**	**AUC**	**Tr.Acc**	**Val.Acc**
ReLU	0.7782	0.7882	0.7877	**0.9436**	**0.9536**	0.7760
Tanh	**0.6523**	**0.7933**	**0.7930**	0.9404	0.8932	**0.7952**

[1]Gap = Tr.Acc − Val.Acc. Valores em **negrito** indicam gap > 0.10 (possível overfitting).

4 Conclusão

O dataset 4, em contraponto à simplicidade dos datasets 1 e 2, mostra que é difícil, mesmo para uma MLP, aproximar a função objetivo de maneira ótima. Os datasets menores e simples se tornam um problema trivial para a robustez de uma MLP. O mesmo não se aplica para datasets complexos, os quais serão abordados ao longo da disciplina, por isso vejo a necessidade (como esperado) de arquiteturas como CNN e Transformers.

No geral, concluo o relatório respondendo as perguntas finais propostas na atividade

Qual otimizador apresentou melhor estabilidade e desempenho. Adam é mais veloz para convergir, mas o SGD apresentou melhor generalização, o que bate com a literatura de ambos.

Quais arquiteturas mostraram sinais de underfitting ou overfitting. O SGD, por ser estocástico, é menos estável e tende a apresentar possível underfitting. Ao combiná-lo com uma arquitetura menor, obtêm-se os piores resultados neste quesito. O overfitting é mais associado a arquitetura sem regularização.

Qual estratégia de regularização foi mais eficaz. A regularização L2 teve uma média e desvio padrão melhores.

Como a função de ativação influenciou os resultados. Menos do que eu esperava, ambas tiveram resultado similares.